
DNB UNRESTRICTED
Open Source Workshop
Data analyse met (Python) Pandas
DeNederlandscheBank
EUROSYSTEEM

Wat is Pandas?

"Pandas is a fast, powerful, flexible and easy to use open source data analysis and manipulation tool, built on top of the Python programming language."

Een Python package, dat gebouwd is boven op het NumPy package

- Beperkt het schrijven van code Python voor het ontsluiten, manipuleren en verwerken van gestructureerde data
- Makkelijke visualisatie via Matplotlib
- Slechts 2 data structuren: Series en DataFrame

Pandas DataFrame

Tabel met 1 of twee dimensies:

- Series: 1-dimensionaal
- DataFrames: 2-dimensionaal (axis=0 zijn de rijen, axis=1 zijn de kolommen)
  - DataFrame is opgebouwd als meerdere series met 1 index

Gebruik van makkelijk te interpreteren namen voor de kolommen/rijen

- Kolommen ≃ Variabelen
- Rijen ≃ Observaties

Overige functionaliteit:

- Lege data velden worden NaN (np.nan).
- Toevoegen/verwijderen van kolommen in een DataFrame moet makkelijk gaan
- Data samenvoegen gebaseerd op de indexes
- Zijn niet gemaakt om van vorm te veranderen

Datatypes in Python

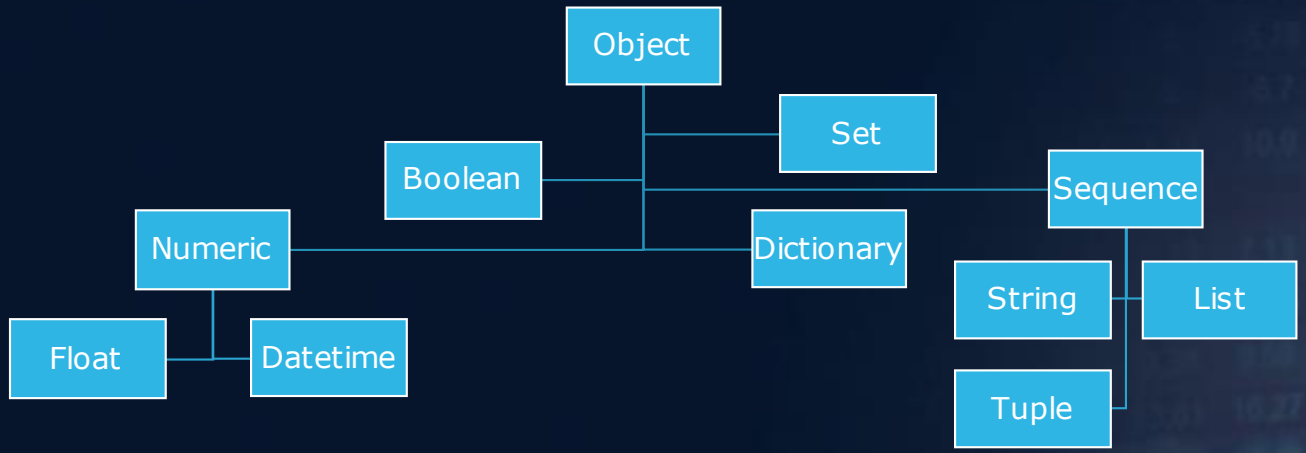

Data combineren

Tabellen A en B willen we samenvoegen op basis van gelijke waarden uit specifieke kolommen.

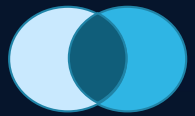

Outer
Alle datapunten meenemen

Inner
Alleen de overlappende data

Left/right
Alle datapunten uit de linker/rechter helft meenemen en de overlappende data

Als de matches niet uniek zijn zullen alle combinaties terug komen in het samengevoegde dataframe

Data analysis met Pandas: Toepassing

- **Verschillende soorten data en databronnen**
  - Wat is een dataframe
  - Data inlezen uit verschillende bronnen voordoen (.read_csv, .read_excel, .read_json)
  - Inlezen van meerdere bestanden
  - Data types (.dtypes, .astype, .head)

- **Data schonen**
  - Ongeldige en ontbrekende waardes (.isna, .isnull, .drop_duplicates, .drop_na)
  - Veel voorkomende datafouten (.describe, .min/max, .quantile, .unique)
  - Data preprocessing (.round)

- **Data combineren**
  - Indexing en filteren in dataframe (.iloc, .loc, .at, chain indexing)
  - Dataframes met elkaar combineren (.merge, .concat, regex)

- **Data analyseren**
  - Transformatie van data (.sort, .drop, .add, .pivot_table, .melt, ,.stack, .unstack, .crosstab)
  - Dataframe berekeningen kolom/rij gebaseerd, itereren (.eval, .apply, .iterrows)
  - Geaggregeerde statistieken (.groupby)
  - Plotten van dataframe (.plot, .plot.hist, .plot.bar)

- **Data wegschrijven**
  - Verschillende opties (.to_csv, .to_excel, .to_pickle)

Data analysis met Pandas: Case study

Covid maatregelen in VS:
- Paycheck Protection Program: Leningen aan kleinbedrijf om mensen in dienst te houden

Zijn deze leningen op de juiste plek terecht gekomen?
- In de sectoren waar het aantal uren dat er gewerkt is het meeste achteruit ging

Extra:
- Op de locaties waar de afname in mobiliteit het grootst was

Data analysis met Pandas: Case study

Vijf databestanden:
- PPP_Loan_Data.csv De individuele leningen uit het PPP (voor grote leningen is enkel een loan_range bekend)
- US_Hours_Worked.json Geaggregeerde aantal gewerkte uren per week per maand vanaf 2019 per sector in duizendtallen seizoensgecorrigeerd
- NAICS.json Sectornamen die bij de sectorcodes (NAICS) horen

Code:
- Workshop_code.ipynb Om de data in te lezen vanuit Google Colab
- OSW_Pandas_us_hours_worked_verwerkt.ipynb Code om de unemployment data na het inlezen te verwerken

Locatie: *https://github.com/mnijhuis-dnb/open_source_workshop*

Extra:
- Global_Mobility_Report.csv Dagelijkse Google mobility indexes vanaf februari
- uszips.xlsx Lijst met postcodes en sensus codes voor de VS